

این مدل شامل خلاصه و نکات مرتبط با NLP - ML و موارد مرتبط می باشد.



بوت کتب Transformers در یک استاندارد جهانی (آپارات)

Session 1: • Sequence processing
• Recurrent Neural Networks (RNNs)


ML:

متغیر مستقل خارجی	متغیر مستقل داخلی	متغیر وابسته قوت
✓	✓	✓
α	α	α
—	—	—

Neural Networks:




این پرسش در یک رابطه و یک معنوی از داده یادگیری هم چنین می تواند به معنای یک مدل
عصبی از چندین مدل عصبی برای مسائل فرعی استفاده کنیم. (شکل زیر)



این شبکه مربوط به شبکه‌ای عصبی است از ساخت غیر فزونی‌کننده می‌کشد.

* اما موضوع برای داده‌های پی‌در پی یا سری‌های زمانی است.




این‌ها همگی شبکه Feed forward است. یعنی برای این یک بار اجرا می‌کنیم و به این می‌رسیم.

این‌ها همگی شبکه Recurrent Neural Network است. یعنی برای این یک بار اجرا می‌کنیم و به این می‌رسیم.

شبکه عصبی بازگشتی Recurrent Neural Network

همچنین در گذشته به آن شبکه عصبی Elman می‌گفتند. شباهتی به Vanilla RNN دارد. هر دو می‌سازند.

* در این نوع شبکه، پیش‌بینی (۲۱ام با توجه به قیاس‌های قبلی ۲۰، ۱۹، ۱۸) به دست می‌آید.



در این و جزئیات شبکه عصبی RNN

$\vec{x}_t$: بردار ورودی


$\vec{a}_{t-1}$: خروجی زمان قبلی (مرحله قبلی)

$\vec{y}_t$: خروجی حال حاضر



* بردارهای $\vec{x}_t$ و $\vec{a}_{t-1}$ با هم Concat می‌شوند.

فرق این داخل یک شبکه ای هستیم و فردی که این کار را می‌کند می‌خواهد بررسی کند که آیا این کار درست است یا نه.




* نوشتارها خور شدن نوعی داده Sequential هستند. چون داده‌ها Sequential هستند باید دنباله‌ای شوند. چگونه؟ ۲ مدل

دنباله از کلمات
دنباله‌ای از کاراکترها

Token

مثال یکی از شبکه‌های RNN شبکه ترجمه ماشینی یا همان Machine Translation است.



این برای این به کار می‌رود که بتواند کلمات را به یکدیگر تبدیل کند و این کار را می‌تواند با استفاده از word embedding انجام دهد.

school → embedding vector

word embedding

Corpus

"she goes to school" $\Rightarrow$ {she, goes, to, school}

Vocabulary

she	He	To	school	...	Eos
1	2	3	4	-	n

تاکید می‌کنم که
1, 2, 3, ... خوب نیستند

چون کلمات به ترتیب 1 < 2 هستند. پس روش خوبی نیست. $she < He$

ما برای رفع این مشکل از بردارهای استنادی می‌زنیم.


she	He	To	school	...	Eos

embedding table


token $\Rightarrow$ embedding layer $\Rightarrow$ embedding vector

Multy-layer RNN

ما در اینجا ۲ تا RNN داریم که ۳ بار یکدیگر را می بینند و RNN ها را می بینند




حقیقت می تواند بیشتر هم باشد



Session 2: • short-term memory & long-term dependancy problem • LSTM / GRU

مثال: "... so he goes to ..."

Text Generation




شما predict می کنید

شما می توانید این را به درستی بگویید

شما می توانید این را به درستی بگویید


جواب) "Don't eat that tasty ice cream"

Classification



★ در اینجا Don't فعلی است زیرا به آن توجه می شود به صورت کامل جواب دسته بندی را تعیین می کند.


★ برای RNN این یک مشکل است. و مشکل ما فاصله دارد.



long-term dependency

★ در اینجا Context Vector داده ای مربوط آخری را دارد

داده ای مربوط اولیه. دقیقاً مانند مشکل زیر




★ همان لحظه از لحظه شروع با گذشت زمان متغیری نیست که می تواند به خاطر می ماند. یعنی در هر لحظه چیزی را نمی تواند به او یادداشت اولیه که می ماند.

مشکل RNN ها = Short-term memory = همین ماهی قرمز

★ اما نکته ای که وجود دارد این است که این مشکل از زمانه سازی قابل جلوگیری است با بزرگ کردن اندازه Context Vector می توان این مشکل را حل کرد. اما نکته ای که هست رابطه مستقیم با Vanishing gradient می شود.


(حل مسئله)

برای غیر بارزگی
RNN



از مدل RNN به LSTM


RNN



LSTM


skip connect W, W_1

cell state = مسیر حافظه بلند مدت




hidden state = حافظه کوتاه مدت

★ در مسیر حافظه بلند مدت هیچ پیچیدگی نباید و فقط اطلاعات باید دست نخورده باقی بماند. Activation تابعی نباید داشته باشد، لایه ای F.F نباید باشد تا پیچیدگی عملیات حفظی ندارد و نتایج داشته باشد.



★ در مسیر حافظه بلند مدت دو عملیات انجام می شود: ۱- پاک کردن ۲- اضافه کردن

(خبره سلول LSTM)



بردار C_t

✓	1.5	x	1
x	2	x	0
✓	7.5	x	1
✓	3	x	1

عمل با هس یا پاک کردن: forget gate
 می خواهیم تمام یا بخشی از این اطلاعات پاک شود. مانند شش مقابل عمل می کنیم.
 برای این کار این عمل باید از یک شبکه FF استفاده کنیم به همراه h_{t-1} و x_t است. این شبکه یاد می گیرد که چه اطلاعاتی باید از ورودی پاک شود. از آن جایی که باید اعداد خروجی FF بین 0 و 1 باشند بنابراین باید از تابع فعال سازی sigmoid استفاده کرد.

عمل اضافه کردن: input gate

می خواهیم یک سری اطلاعات اضافه کنیم بر اصل مانند عمل قبل است اما با این تفاوت که از تابع فعال سازی tanh استفاده می کنیم، اما نکته ای که هست ما هس این اطلاعاتی که مدنظر است نمی خواهیم اضافه شود بنابراین باید یک گیت (شیر شبکه) دیگر اضافه کنیم در واقع دقت کنید این گیت این است که چه راز این اطلاعات را اضافه کنیم

خبره یا پایی: output gate

در خبره یا پایی اطلاعات ما باید بین یک رنجی فکر کنیم به همین دلیل از tanh استفاده می کنیم هم چنین ما می خواهیم که این اطلاعات به هر دو بهی منتقل شود بنابراین از یک گیت یا شیر شبکه دیگر بهی مستقل استفاده می کنیم.



* نوع معروفتری از شبکه های LSTM وجود دارد

Gate Recurrent Unit

GRU

* GRU تلاش به این دارد تا LSTM را سبک تر کند یعنی سبکتر در GRU اینطور می باشد که LSTM می باشد.

* GRU input Gate, output Gate و reset دارد.





* این و در GRU و LSTM می باشد. LSTM را سبک تر کرد یعنی سبکتر در GRU اینطور می باشد که LSTM می باشد.



Session 3 : Encoder - Decoder Architecture

Attention mechanism

- Machine translation




many to one
 * در جایی که تعداد بایر نیست با دهنده
 نامیده می شود اما در حال غذا خوردن است : می شود
 many to one در این بولت 'he is eating'
 واضح.



Decode with LSTM
 Content vector

seq to seq $\hookrightarrow$ sequence to sequence

بله این یک نوع معماری برای حل مسائل Seq to Seq می باشد که دو جنبه جدا از هم دارد که به نام های Encoder و Decoder شناخته می شوند.



* input sequence کے words کو token-token vector میں Content vector میں دیا جائے گا۔
 * Decoder پر یہ عمل! کہ ہلایا جائے: غزلان غزلان غزلان۔
 * Gradient vanishing کی مسئلہ۔

A → Encoder-Decoder, x , y من جمله داریم: Content vector فقط اطلاعات مربوطه را دارد. Decoder اطلاعات را در طی این فرآیند به Encoder میدهد.

آن‌ها دوست گاهه یک خودکار فرم‌جاست، ادای خودکار را به من داد. (میل)

$SO_3 \rightarrow \rightarrow \text{AmNH}$


★ در اینجا توجه: آنا ضمیرا فعلی هم هست تا توجه:

★ در اینجا خود را اضافه می‌کنیم تا حرفه‌ای
باشد چون اگر نه به نظر می‌آید که She
است و نه است


آنحضرت دوست کا وہ ایک خودکار فرزند ہے۔ اراکین خودکار ہیں داد۔

Attention mechanism

مکانیزم توجه به اساس بر این عمل می‌گردد و فقط به بخشی از یک متن توجه می‌کند.
 * مقدار توجه یا Attention Score می‌تواند تغییر کند. با توجه به دردی تصمیم می‌گیرد کدام کلمه دردی
 مهم ترند.




مکانیزم Encoder-Decoder به طور معمول بین نقل و انت
 است و خیلی درست و اشتباه خوبی هم می‌کند
 اما vector هست و در Decoder می‌تواند به 'شهر' اشاره
 بدهد و به این شکل در هر کلمه باید توجه داشت هر کلمه با هم
 اهمیت (توجه) خاصی به است (ای Decoder) دارد می‌شود.




مکانیزم توجه که در است 'she'
 قرار دارد باید از بین کلمات برای موجود به کلمه
 یک امتیازی بدهد. (امتیاز مبنای بودن)


Retrieval system



کلمات: $K = tag + key$
 ... و اینها خود را Value می‌دهند




ما به مکانیزم توجه به به یک Retrieval system می‌گوییم.



هین استی های هر مدار از V و K Encoder
 هین استی RNN مربوط به Q Decoder.



Attention block



Session 4 (final):


- Transformers
- LLMs

ما می‌توانیم برای این attention و قدرتمند تر می‌توانیم از attention unit ای بگری استفاده کنیم



multi-head attention

Encoder - Decoder Arch (پاد روی)



این معماری به خوبی مفهوم seq to seq را می‌آموزد

این معماری داخل Encoder-Decoder از RNN استفاده می‌کند علاوه بر این می‌تواند به صورت همزمان کار کند

بدون این است. (سری زمانی کاری با این است) بنابراین خوب است به جای اینکه دنبال بوی با این








تک یک واحد را به صورت تدریجی دنبال هم بینیم که روی یک به ازای کنیم که مقدره فلان Transformer

مگر، به جای می‌توانیم از آن‌ها استفاده کنیم. اما چون در RNN و LSTM به صورت تدریجی یاد گرفته می‌شود به همین دلیل که به صورت تدریجی یاد گرفته می‌شود، اما چون معماری Transformer این کار نیست به همین دلیل هم یاد گرفته نمی‌شود.

Transformer

Hi, how are you?


final content vector












Hi, how are you? Eos

Hi, how are you?

Next token



output token Embedding




Hey! Thanks! I'm Next token

hey! Thanks! I'm ...

Positional Encoding: Embedding را با موقعیت ها ترکیب می کنیم.

Pos: همان 1, 2, 3, 4, ... در ترتیب است.



$$\sin \frac{\text{pos}}{(10,000)^{\frac{2i}{d}}}$$

$$\cos \frac{\text{pos}}{(10,000)^{\frac{2i}{d}}}$$

Strategies for selecting softmax = { Greedy, Random }

Attention { self-Attention, Cross-Attention = Connection Q! K, V های (S, T) }

Transformers { Encoder-Decoder: TS, (Generator)
Encoder only: Bert (Sentiment analysis)
Decoder only: GPT (Generator) }